



به نام خدا
دانشگاه اصفهان
دانشکده مهندسی کامپیوتر

گزارش سوال دوم از تمرین اول
درس مبانی یادگیری ماشین

استاد درس:
دکتر جمالی

امین ماهوش محمدی
(4023613063)

تمام متن نوشته شده در اینجا، در فایل `home pricing.ipynb` بعد از هر قطعه کد آورده شده است. توصیه میشود برای فهم بهتر متن هارا در این فایل مشاهده کنید.

پیش پردازش

الان که دیتاست آپلود شد باید پیش پردازش کنیم
یعنی دیتاست را برای `train` تمیز کنیم

تابع: `info`

با استفاده از این تابع جزئیات کامل دیتاست را اعم از تایپ و تعداد مقادیر غیر خالی هر ویژگی

تابع: `describe`

این تابع جزئیات کامل آمار توصیفی اعم از میانه و میانگین و واریانس و چارک های داده های عددی و فراوانی و داده های غیر عددی

تابع: `isna`

این تابع تعداد سلول های خالی هر ویژگی را نمایش میدهد

با استفاده از عدد واریانس میتوان دید که آیا دیتاست ما داده های پرت زیادی دارد یا نه
اگر واریانس به ۰ نزدیک باشد میتوانیم بگوییم که داده پرت زیادی ندارد

برای پر کردن سلول های خالی بهتر

برای ویژگی های پیوسته به واریانس نگاه میکنیم اگر واریانس زیاد باشد بهتر است از میانه استفاده کنیم

اما اگر واریانس نزدیک به صفر باشد از میانگین استفاده میکنیم

اما به طور قطع نمیتوان با واریانس فراوانی داده های پرت را حساب کرد

پس از `IQR` برای احتساب این مقادیر استفاده میکنیم

برای داده های پیوسته و میانگین و واریانس معنایی ندارد

برای این ویژگی ها یا از مد استفاده میکنیم یا از میانه

بهتر هست که از میانه استفاده کنیم

برای داده پر کردن سلول های غیر عددی

تنها راه حل استفاده از مد یا همان فراوانی هست که کم ریسک ترین راه حل هست

داده هایی که بیشتر از $Q3 + 1.5 * IQR$ باشند

یا کمتر از $Q1 - 1.5 * IQR$ باشند

داده های پرت محسوب میشوند

اما برای داده های پیوسته حساب میکنیم

چون برای پر کردن سلول های خالی ویژگی های گسسته از میانه استفاده میکنیم.

به دلیل وجود داده های پرت بهتر است برای ویژگی های پیوسته هم از میانه استفاده کنیم

پس تمام سلول های خالی را با میانه پر کردیم.

مصور سازی

با این ماتریس همبستگی فهمیدیم که متراف با قیمت همبستگی خوبی دارد که تقریباً متوسط هست

و همینطور اتاق خواب و دستشویی هم با قیمت خانه همبستگی خوب و متوسطی دارد

پس برای ترین مدل از این مدل های استفاده میکنیم

اما اگر که افراد پیشنهادی این خانه هست چون همبستگی منفی دارد از این ویژگی استفاده نمیکنیم

با این نمودار scatterplot و regplot میفهمیم که تقریباً رابطه قیمت و متراف خطی با شیب مثبت هست

البته داده های پرتی هم واضحاً دیده میشود

با این نمودار میفهمیم که رابطه تعداد دستشویی با قیمت خانه مثبت هست اما خطی نیست

با این نمودار میفهمیم که رابطه تعداد اتاق خواب با قیمت خانه ضعیف هست

خانه های با ۳ اتاق خواب بیشترین تنوع قیمتی را دارند

با این نمودار فهمیدیم خانه هایی که آجری هستند میانگین قیمت بالاتری دارند.

میان قیمت برای Yes به بالاتر از No است.

این ویژگی تأثیر نسبتاً قوی دارد.

با این نمودار فهمیدی که محله های مختلف تأثیر زیادی در قیمت خانه دارد

پس این ویژگی تأثیر قوی دارد.

در نهایت میتوان گفت آن ویژگی هایی که تأثیر مثبت و قوی دارند را برای ترین مدل استفاده میکنیم

پیشنهادهای که همبستگی منفی داشت در این مدل استفاده نکنیم

آماده‌سازی داده و نرمال‌سازی

ابتدا مقادیر غیر عددی را با استفاده از تابع `get_dummies` عددی میکنیم

حال برای نرمالایز کردن دیتای ورودی

از کلاس `StandardScaler` مینویسیم که متد `fit` هاست که واریانس و میانگین را حساب میکند و متد بعدی `transform` هاست که داده‌ها را با استفاده از میانگین و انحراف معیار استاندارد میکند یعنی از هر مقدار میانگین را کم میکند و تقسیم بر انحراف معیار میکند

و متد آخر یعنی `fit_transform` هر دو کار را با هم انجام میدهد

داده‌های `train` را `fit_transform` میکنیم ولی داده‌های `test` را فقط `transform` میکنیم برای اینکه اگر داده‌های `test` را هم `fit` کنیم باعث نشت اطلاعات میشود و دیگر ارزیابی مدل درست در نمی‌آید

کلاس `LinearRegressionGD` رگرسیون خطی را با روش گرادیان کاهشی از ابتدا پیاده‌سازی کردیم

اول بایاس به ماتریس ویژگی اضافه میشود

و متد `fit` وزن‌ها را با محاسبه گرادیان خطا بر اساس داده‌های `train` تنظیم میکنیم و با یک حلقه در هر تکرار بروزرسانی میکنیم

و متد `predict` با ضرب ماتریس ویژگی‌ها که با بایاس حساب شده بود در وزن‌هایی که در متد `fit` تنظیم شده بود مقادیر پیش‌بینی شده را حساب میکند

و متد `score` ضریب تعیین را محاسبه میکند

اینجا مدل رگرسیون خطی را با نرخ یادگیری ۰.۰۱ و ۱۰۰۰ تکرار می‌سازد، روی داده‌های `train` نرمال‌شده `train` میکند و بعد R^2 ضریب تعیین (را برای هر دو داده `train` و `test` حساب میکند). خروجی نشان می‌دهد مدل حدود ۸۶٪ و ۸۹٪ از تغییرات قیمت را به ترتیب در `train` و `test` توضیح می‌دهد که عملکرد بسیار خوبی است.

این نمودار پراکندگی باقیمانده‌ها یعنی همون خطای پیش‌بینی را در برابر قیمت واقعی برای بررسی تصادفی بودن خطاها و عدم وجود الگو (روند، خوشه‌ای یا واریانس ناهمسانی).

خط قرمز صفر نشان‌دهنده خطای صفر است.

تابع هدف

این کد تابع `rmse` جذر میانگین مربعات اختلاف بین قیمت واقعی و پیش‌بینی را محاسبه می‌کند. این خروجی یعنی مدل میانگین خطای پیش‌بینی قیمت را حدود ۹۷۰۰ تا ۹۹۰۰ دلار دارد و خطای `test` کمی کمتر از `train` است و این یعنی عملکرد مدل خوب بوده.